

Linear Classification 05 Gaussian Discriminate Analysis

Chen Gong

03 November 2019

前面讲的方法都是概率判别模型，包括，Logistic Regression 和 Fisher 判别分析。接下来我们要学习的是概率生成模型部分，也就是现在讲到的 Gaussian Discriminate Analysis。数据集的相关定义为：

$$X = (x_1, x_2, \dots, x_N)^T = \begin{pmatrix} x_1^T \\ x_2^T \\ \vdots \\ x_N^T \end{pmatrix} = \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1p} \\ x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{N1} & x_{N2} & \dots & x_{Np} \end{pmatrix}_{N \times P} \quad (1)$$

$$Y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{pmatrix}_{N \times 1} \quad (2)$$

那么，我们的数据集可以记为 $\{(x_i, y_i)\}_{i=1}^N$ ，其中， $x_i \in \mathbb{R}^P$ ， $y_i \in \{+1, -1\}$ 。我们将样本点分成了两个部分：

$$\begin{cases} C_1 = \{x_i | y_i = 1, i = 1, 2, \dots, N_1\} \\ C_2 = \{x_i | y_i = 0, i = 1, 2, \dots, N_2\} \end{cases} \quad (3)$$

并且有 $|C_1| = N_1$ ， $|C_2| = N_2$ ，且 $N_1 + N_2 = N$ 。

1 概率判别模型与生成模型的区别

什么是判别模型？所谓判别模型，也就是求

$$\hat{y} = \arg \max_y p(y|x) \quad y \in \{0, 1\} \quad (4)$$

重点在于求出这个概率来，知道这个概率的值等于多少。而概率生成模型则完全不一样。概率生成模型不需要知道概率值具体是多大，只需要知道谁大谁小即可，具体是对联合概率进行建模。举例即为 $p(y = 0|x)$ 和 $p(y = 1|x)$ ，谁大谁小的问题。而概率生成模型的求法可以用贝叶斯公式来进行求解，即为：

$$p(y|x) = \frac{p(x|y)p(y)}{p(x)} = \frac{p(x, y)}{p(x)} \propto p(x, y) \quad (5)$$

因为在这个公式中，比例大小 $p(x)$ 与 y 的取值无关，所以它是一个定值。所以，概率生成模型实际上关注的就是一个求联合概率分布的问题。那么，总结一下

$$p(y|x) \propto p(x|y)p(y) \propto p(x, y) \quad (6)$$

其中， $p(y|x)$ 为 Posterior function, $p(y)$ 为 Prior function, $p(x|y)$ 为 Likelihood function。所以有

$$\hat{y} = \arg \max_{y \in \{0,1\}} p(y|x) \propto \arg \max_{y \in \{0,1\}} p(x|y)p(y) \quad (7)$$

2 Gaussian Discriminate Analysis 模型建立

在二分类问题中，很显然可以得到，我们的先验概率符合， $p(y) \sim \text{Bernoulli Distribution}$ 。也就是，

y	1	0
p	φ	$1 - \varphi$

表 1: Bernoulli 分布的概率分布表

所以，可以写出：

$$p(y) = \begin{cases} \varphi^y & y = 1 \\ (1 - \varphi)^{1-y} & y = 0 \end{cases} \Rightarrow \varphi^y(1 - \varphi)^{1-y} \quad (8)$$

而随后是要确定**似然函数**，我们假设他们都符合高斯分布。对于不同的分类均值是不同的，但是不同变量之间的协方差矩阵是一样的。那么我们可以写出如下的形式：

$$p(x|y) = \begin{cases} p(x|y=1) \sim \mathcal{N}(\mu_1, \Sigma) \\ p(x|y=0) \sim \mathcal{N}(\mu_2, \Sigma) \end{cases} \Rightarrow \mathcal{N}(\mu_1, \Sigma)^y \mathcal{N}(\mu_2, \Sigma)^{1-y} \quad (9)$$

那么我们的 Likelihood function 可以被定义为：

$$\begin{aligned} \mathcal{L}(\theta) &= \log \prod_{i=1}^N p(x_i, y_i) \\ &= \sum_{i=1}^N \log p(x_i, y_i) \\ &= \sum_{i=1}^N \log p(x_i|y_i)p(y_i) \\ &= \sum_{i=1}^N [\log p(x_i|y_i) + \log p(y_i)] \\ &= \sum_{i=1}^N [\log \mathcal{N}(\mu_1, \Sigma)^{y_i} \mathcal{N}(\mu_2, \Sigma)^{1-y_i} + \log \varphi^{y_i}(1 - \varphi)^{1-y_i}] \\ &= \sum_{i=1}^N \log \mathcal{N}(\mu_1, \Sigma)^{y_i} + \sum_{i=1}^N \log \mathcal{N}(\mu_2, \Sigma)^{1-y_i} + \sum_{i=1}^N \log \varphi^{y_i} + \sum_{i=1}^N \log(1 - \varphi)^{1-y_i} \end{aligned} \quad (10)$$

为了方便后续的推演过程，所以，我们将 Likelihood function 写成，

$$\mathcal{L}(\theta) = \textcircled{1} + \textcircled{2} + \textcircled{3}$$

并且, 我们令: $\textcircled{1} = \sum_{i=1}^N \log \mathcal{N}(\mu_1, \Sigma)_i^{y_i}$, $\textcircled{2} = \sum_{i=1}^N \log \mathcal{N}(\mu_2, \Sigma)^{1-y_i}$,
 $\textcircled{3} = \sum_{i=1}^N \log \varphi^{y_i} + \sum_{i=1}^N \log(1-\varphi)^{1-y_i}$ 。那么上述函数我们可以表示为:

$$\theta = (\mu_1, \mu_2, \Sigma, \varphi) \quad \hat{\theta} = \arg \max_{\theta} \mathcal{L}(\theta) \quad (11)$$

3 Likelihood function 参数的极大后验估计

Likelihood function 的参数为 $\theta = (\mu_1, \mu_2, \Sigma, \varphi)$, 下面我们分别用极大似然估计对这四个参数进行求解。下面引入几个公式:

$$\text{tr}(AB) = \text{tr}(BA) \quad (12)$$

$$\frac{\partial \text{tr}(AB)}{\partial A} = B^T \quad (13)$$

$$\frac{\partial |A|}{\partial A} = |A| A^{-T} \quad (14)$$

$$\frac{\partial \log |A|}{\partial A} = A^{-T} \quad (15)$$

3.1 求解 φ

$$\textcircled{3} = \sum_{i=1}^N \log \varphi^{y_i} + \sum_{i=1}^N \log(1-\varphi)^{1-y_i} = \sum_{i=1}^N y_i \log \varphi + \sum_{i=1}^N (1-y_i) \log(1-\varphi)$$

$$\frac{\partial \textcircled{3}}{\partial \varphi} = \sum_{i=1}^N y_i \frac{1}{\varphi} - \sum_{i=1}^N (1-y_i) \frac{1}{1-\varphi} = 0 \quad (16)$$

$$\sum_{i=1}^N y_i(1-\varphi) - (1-y_i)\varphi = 0 \quad (17)$$

$$\sum_{i=1}^N (y_i - \varphi) = 0 \quad (18)$$

$$\hat{\varphi} = \frac{1}{N} \sum_{i=1}^N y_i \quad (19)$$

又因为 $y_i = 0$ 或 $y_i = 1$, 所以 $\hat{\varphi} = \frac{1}{N} \sum_{i=1}^N y_i = \frac{N_1}{N}$ 。

3.2 求解 μ_1

$$\begin{aligned} \textcircled{1} &= \sum_{i=1}^N \log \mathcal{N}(\mu_1, \Sigma)^{y_i} \\ &= \sum_{i=1}^N y_i \log \frac{1}{(2\pi)^{\frac{p}{2}} |\Sigma|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (x_i - \mu_1)^T \Sigma^{-1} (x_i - \mu_1) \right\} \end{aligned}$$

那么求解过程如下所示: 由于对 μ_1 求偏导, 我们只需要关注公式中和 μ_1 有关的部分。那么我们可以将问题简化为:

$$\max_{\mu_1} \sum_{i=1}^N y_i \log \exp \left\{ -\frac{1}{2} (x_i - \mu_1)^T \Sigma^{-1} (x_i - \mu_1) \right\} \quad (20)$$

然后将 \exp 和 \log 抵消掉，再将括号打开，我们可以得到最终的化简形式：

$$\max_{\mu_1} -\frac{1}{2} \sum_{i=1}^N y_i \{x_i^T \Sigma^{-1} x_i - 2\mu_1^T \Sigma^{-1} x_i + \mu_1^T \Sigma^{-1} \mu_1\} \quad (21)$$

为了方便表示，我们令① = Δ 。所以，极大似然法求解过程如下：

$$\begin{aligned} \frac{\partial \Delta}{\partial \mu_1} &= -\frac{1}{2} \sum_{i=1}^N y_i (-2\Sigma^{-1} x_i + 2\Sigma^{-1} \mu_1) = 0 \\ &= \sum_{i=1}^N y_i (\Sigma^{-1} x_i - \Sigma^{-1} \mu_1) = 0 \\ &= \sum_{i=1}^N y_i (x_i - \mu_1) = 0 \\ &= \sum_{i=1}^N y_i x_i = \sum_{i=1}^N y_i \mu_1 \\ \mu_1 &= \frac{\sum_{i=1}^N y_i x_i}{\sum_{i=1}^N y_i} = \frac{\sum_{i=1}^N y_i x_i}{N_1} \end{aligned} \quad (22)$$

3.3 求解 μ_2

μ_2 的求解过程与 μ_1 的基本保持一致性。区别点从公式 (22) 开始，我们有：

$$\max_{\mu_2} -\frac{1}{2} \sum_{i=1}^N (1 - y_i) \{x_i^T \Sigma^{-1} x_i - 2\mu_2^T \Sigma^{-1} x_i + \mu_2^T \Sigma^{-1} \mu_2\} \quad (23)$$

极大似然法的求解过程如下所示：

$$\begin{aligned} \frac{\partial \Delta}{\partial \mu_2} &= -\frac{1}{2} \sum_{i=1}^N (1 - y_i) (-2\Sigma^{-1} x_i + 2\Sigma^{-1} \mu_2) = 0 \\ &= \sum_{i=1}^N (1 - y_i) (x_i - \mu_2) = 0 \\ &= \sum_{i=1}^N x_i - \sum_{i=1}^N y_i x_i = N\mu_2 - \sum_{i=1}^N y_i \mu_2 \\ \mu_2 &= \frac{\sum_{i=1}^N x_i - \sum_{i=1}^N y_i x_i}{N - \sum_{i=1}^N y_i} = \frac{\sum_{i=1}^N x_i - \sum_{i=1}^N y_i x_i}{N - N_1} \\ &= \frac{\sum_{i=1}^N (1 - y_i) x_i}{N_2} \end{aligned} \quad (24)$$

也可以对于求 μ_1 来说，求 μ_2 可以类比，将其中的 N_1 换成 N_2 ，其中的 y_i 换成 $1 - y_i$ ，可以得到同样的结果。

3.4 求解 Σ

如果要使用极大似然估计来求解 Σ ，这只会与 $\mathcal{L}(\theta)$ 中的①和②有关。并且①+②的表达式为：

$$\sum_{i=1}^N \log \mathcal{N}(\mu_1, \Sigma)^{y_i} + \sum_{i=1}^N \log \mathcal{N}(\mu_2, \Sigma)^{1-y_i} \quad (25)$$

那么，按照分类点的方法，我们可以将其改写为：

$$\hat{\Sigma} = \arg \min_{\Sigma} \sum_{x \in C_1} \log \mathcal{N}(\mu_1, \Sigma) + \sum_{x \in C_2} \log \mathcal{N}(\mu_2, \Sigma) \quad (26)$$

公式加号前后都是一样的，所以，为了方便计算我们暂时只考虑一半的计算：

$$\begin{aligned} \sum_{i=1}^N \log \mathcal{N}(\mu, \Sigma) &= \sum_{i=1}^N \log \frac{1}{(2\pi)^{\frac{p}{2}} |\Sigma|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (x_i - \mu)^T \Sigma^{-1} (x_i - \mu) \right\} \\ &= - \sum_{i=1}^N \frac{p}{2} \log 2\pi - \sum_{i=1}^N \frac{1}{2} \log |\Sigma| - \frac{1}{2} (x_i - \mu)^T \Sigma^{-1} (x_i - \mu) \\ &= C - \frac{N}{2} \log |\Sigma| - \frac{1}{2} \sum_{i=1}^N (x_i - \mu)^T \Sigma^{-1} (x_i - \mu) \\ &= C - \frac{N}{2} \log |\Sigma| - \frac{1}{2} \sum_{i=1}^N \text{tr}((x_i - \mu)^T \Sigma^{-1} (x_i - \mu)) \\ &= C - \frac{N}{2} \log |\Sigma| - \frac{1}{2} \sum_{i=1}^N \text{tr}((x_i - \mu)(x_i - \mu)^T \Sigma^{-1}) \end{aligned} \quad (27)$$

而且，

$$S = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)(x_i - \mu)^T \quad (28)$$

所以，

$$\sum_{i=1}^N \log \mathcal{N}(\mu, \Sigma) = C - \frac{N}{2} \log |\Sigma| - \frac{N}{2} \text{tr}(S \Sigma^{-1}) \quad (29)$$

那么代入公式 (27) 中，我们可以得到：

$$\begin{aligned} \hat{\Sigma} &= \arg \max_{\Sigma} C - \frac{N_1}{2} \log |\Sigma| - \frac{N_1}{2} \text{tr}(S_1 \Sigma^{-1}) + C - \frac{N_2}{2} \log |\Sigma| - \frac{N_2}{2} \text{tr}(S_2 \Sigma^{-1}) \\ &= \arg \max_{\Sigma} -\frac{N}{2} \log |\Sigma| - \frac{N_1}{2} \text{tr}(S_1 \Sigma^{-1}) - \frac{N_2}{2} \text{tr}(S_2 \Sigma^{-1}) \\ &= \arg \min_{\Sigma} N \log |\Sigma| + N_1 \text{tr}(S_1 \Sigma^{-1}) + N_2 \text{tr}(S_2 \Sigma^{-1}) \end{aligned} \quad (30)$$

我们令函数 $N \log |\Sigma| + N_1 \text{tr}(S_1 \Sigma^{-1}) + N_2 \text{tr}(S_2 \Sigma^{-1}) = \Delta$ ，那么对 Σ 求偏导并令其等于 0 可得：

$$\frac{\partial \Delta}{\partial \Sigma} = N \Sigma^{-1} - N_1 \Sigma^{-1} S_1 \Sigma^{-1} - N_2 \Sigma^{-1} S_2 \Sigma^{-1} = 0 \quad (31)$$

对上式左乘 Σ ，又乘 Σ 得到 $N \Sigma - N_1 S_1 - N_2 S_2 = 0$ 。

解得：

$$\Sigma = \frac{N_1 S_1 + N_2 S_2}{N} \quad (32)$$

其中对 $\text{tr}(S_1 \Sigma^{-1})$ 求偏导的过程如下（由于 $\Sigma \Sigma^{-1} = \mathbb{I}$ ，所以 $d(\Sigma^{-1} \Sigma) = \mathbb{O} \Rightarrow (d \Sigma) \Sigma^{-1} + \Sigma d(\Sigma^{-1}) = 0 \Rightarrow d \Sigma^{-1} = -\Sigma^{-1} (d \Sigma) \Sigma^{-1}$ ：

$$\begin{aligned} d \text{tr}(S_1 \Sigma^{-1}) &= \text{tr}(S_1 d \Sigma^{-1}) \\ &= \text{tr}(-S_1 \Sigma^{-1} (d \Sigma) \Sigma^{-1}) \\ &= \text{tr}(-\Sigma^{-1} S_1 \Sigma^{-1} d \Sigma) \end{aligned} \quad (33)$$

于是 $\frac{\partial \text{tr}(S_1 \Sigma^{-1})}{\partial \Sigma} = -\Sigma^{-1} S_1 \Sigma^{-1}$ 。同理可以知道 $\frac{\partial \text{tr}(S_2 \Sigma^{-1})}{\partial \Sigma} = -\Sigma^{-1} S_2 \Sigma^{-1}$ 。

4 总结

下面对 Gaussian Discriminate Analysis 做一个简单的小结。我们使用模型为：

$$\hat{y} = \arg \max_{y \in \{0,1\}} p(y|x) \propto \arg \max_{y \in \{0,1\}} p(x|y)p(y) \quad (34)$$

$$\begin{cases} p(y) = \varphi^y(1 - \varphi)^{1-y} \\ p(x|y) = \mathcal{N}(\mu_1, \Sigma)^y \mathcal{N}(\mu_2, \Sigma)^{1-y} \end{cases} \quad (35)$$

利用极大似然估计得到的结果为：

$$\theta = (\mu_1, \mu_2, \Sigma, \varphi) = \begin{cases} \hat{\varphi} = \frac{N_1}{N} \\ \mu_1 = \frac{\sum_{i=1}^N y_i x_i}{N_1} \\ \mu_2 = \frac{\sum_{i=1}^N (1-y_i) x_i}{N_2} \\ \Sigma = \frac{N_1 S_1 + N_2 S_2}{N} \end{cases} \quad (36)$$