

Expectation Maximization 01 Algorithm Convergence

Chen Gong

17 December 2019

Expectation Maximization (EM) 算法, 是用来解决具有隐变量的模型的概率计算问题。在比较简单的情况中, 我们可以直接得出我们想要求得的参数的解析解, 比如: MLE: $p(X|\theta)$ 。我们想要求解的结果就是:

$$\theta_{MLE} = \arg \max_{\theta} \log p(X|\theta) \quad (1)$$

然而一旦问题变得复杂起来以后, 就不是这么简单了, 特别是引入了隐变量之后。

1 EM 算法简述

实际上, EM 算法的描述也并不是很难, 我们知道, 通常我们想求的似然函数为 $p(X|\theta)$ 。引入隐变量之后, 原式就变成了:

$$p(X|\theta) = \int \log p(X, Z|\theta) p(Z|X, \theta) dZ \quad (2)$$

EM 算法是一种迭代的算法, 我们的目标是求:

$$\begin{aligned} \theta^{(t+1)} &= \arg \max_{\theta} \int \log p(X, Z|\theta) p(Z|X, \theta^{(t)}) dZ \\ &= \arg \max_{\theta} \mathbb{E}_{Z \sim p(Z|X, \theta^{(t)})} [\log p(X, Z|\theta)] \end{aligned} \quad (3)$$

也就是找到一个更新的参数 θ , 使得 $\log p(X, Z|\theta)$ 出现的概率更大。

2 EM 算法的收敛性

我们想要证的是当 $\theta^{(t)} \rightarrow \theta^{(t+1)}$ 时, 有 $\log p(X|\theta^{(t)}) \leq \log p(X|\theta^{(t+1)})$ 。这样才能说明我们的每次迭代都是有效的。

$$\log p(X|\theta) = \log \frac{p(X, Z|\theta)}{p(Z|X, \theta)} = \log p(X, Z|\theta) - \log p(Z|X, \theta) \quad (4)$$

下一步, 则是同时对两边求关于 $p(Z|X, \theta^{(t)})$ 的期望。

左边:

$$\begin{aligned} \mathbb{E}_{Z \sim p(Z|X, \theta^{(t)})} [\log p(X|\theta)] &= \int \log p(X|\theta) p(Z|X, \theta^{(t)}) dZ \\ &= \log p(X|\theta) \int p(Z|X, \theta^{(t)}) dZ \\ &= \log p(X|\theta) \cdot 1 = \log p(X|\theta) \end{aligned} \quad (5)$$

右边：

$$\underbrace{\int_Z p(Z|X, \theta^{(t)}) \log p(X, Z|\theta) dZ}_{Q(\theta, \theta^{(t)})} - \underbrace{\int_Z p(Z|X, \theta^{(t)}) \log p(Z|X, \theta) dZ}_{H(\theta, \theta^{(t)})} \quad (6)$$

大家很容易就观察到， $Q(\theta, \theta^{(t)})$ 就是我们要求的 $\theta^{(t+1)} = \arg \max_{\theta} \int_Z p(X, Z|\theta) p(Z|X, \theta^{(t)}) dZ$ 。那么，根据定义，我们可以很显然的得到： $Q(\theta^{(t+1)}, \theta^{(t)}) \geq Q(\theta, \theta^{(t)})$ 。当 $\theta = \theta^{(t)}$ 时，等式也是显然成立的，那么我们可以得到：

$$Q(\theta^{(t+1)}, \theta^{(t)}) \geq Q(\theta^{(t)}, \theta^{(t)}) \quad (7)$$

这时，大家想一想，我们已经得到了 $Q(\theta^{(t+1)}, \theta^{(t)}) \geq Q(\theta^{(t)}, \theta^{(t)})$ 了。如果， $H(\theta^{(t+1)}, \theta^{(t)}) \leq H(\theta^{(t)}, \theta^{(t)})$ 。我们就可以很显然的得出， $\log p(X|\theta^{(t)}) \leq \log p(X|\theta^{(t+1)})$ 了。

证明：

$$\begin{aligned} H(\theta^{(t+1)}, \theta^{(t)}) - H(\theta^{(t)}, \theta^{(t)}) &= \int_Z p(Z|X, \theta^{(t)}) \log p(Z|X, \theta^{(t+1)}) dZ - \int_Z p(Z|X, \theta^{(t)}) \log p(Z|X, \theta^{(t)}) dZ \\ &= \int_Z p(Z|X, \theta^{(t)}) \log \frac{p(Z|X, \theta^{(t+1)})}{p(Z|X, \theta^{(t)})} dZ \\ &= -KL(p(Z|X, \theta^{(t)}) || p(Z|X, \theta^{(t+1)})) \leq 0 \end{aligned} \quad (8)$$

或者，我们也可以使用 Jensen inequality。很显然， \log 函数是一个 concave 函数，那么有 $\mathbb{E}[\log X] \leq \log[\mathbb{E}[X]]$ ，那么：

$$\begin{aligned} \int_Z p(Z|X, \theta^{(t)}) \log \frac{p(Z|X, \theta^{(t+1)})}{p(Z|X, \theta^{(t)})} dZ &= \mathbb{E}_{Z \sim p(Z|X, \theta^{(t)})} \left[\log \frac{p(Z|X, \theta^{(t+1)})}{p(Z|X, \theta^{(t)})} \right] \\ &\leq \log \left[\mathbb{E}_{Z \sim p(Z|X, \theta^{(t)})} \left[\frac{p(Z|X, \theta^{(t+1)})}{p(Z|X, \theta^{(t)})} \right] \right] \\ &= \log \left[\int_Z p(Z|X, \theta^{(t)}) \left[\frac{p(Z|X, \theta^{(t+1)})}{p(Z|X, \theta^{(t)})} \right] dZ \right] \\ &= \log \int_Z p(Z|X, \theta^{(t+1)}) dZ \\ &= 0 \end{aligned} \quad (9)$$

所以，从两个方面我们都证明了， $\log p(X|\theta^{(t)}) \leq \log p(X|\theta^{(t+1)})$ 。那么，经过每次的迭代，似然函数在不断的增大。这就证明了我们的更新是有效的，也证明了算法是收敛的。